複数 CLI AI エージェントの並行運用を支える 状態-表情分離アーキテクチャ

可視化システム kaoiro の設計

櫻井 雄大(桃山学院大学) ・ sakurai@andrew.ac.jp

複数 AI エージェントの並行運用において、内部状態をどこまでオペレータへ 露出するかは、タスク性能だけでは定まらない設計軸である。
kaoiro は観測可能性側の一端に立ち、状態機械を一次信号、表情表現を別レイヤとして 設計・実装した。

示したこと 実行状態の一次信号化と表情表現の分離という設計軸の提示と、その一方の極に立つ実装(状態導出・可視化・複数エージェント集約・権限承認・エージェント間メッセージング)を実装したこと。

まだ示していないこと 状態把握コストの軽減・信頼校正の適正化・心理的距離への効果など、人間側の行動指標に対する定量評価。表示条件間の人間行動比較は今後の研究計画。

課題:異なる 2 つの問題

	何が課題か	対応する設計要素
(A) 実用	並行運用時、各エージェントの状態・進捗を一覧で把握しにくい	状態の可視化
(B) 情緒	協働相手としての心理的距離	キャラクター表現

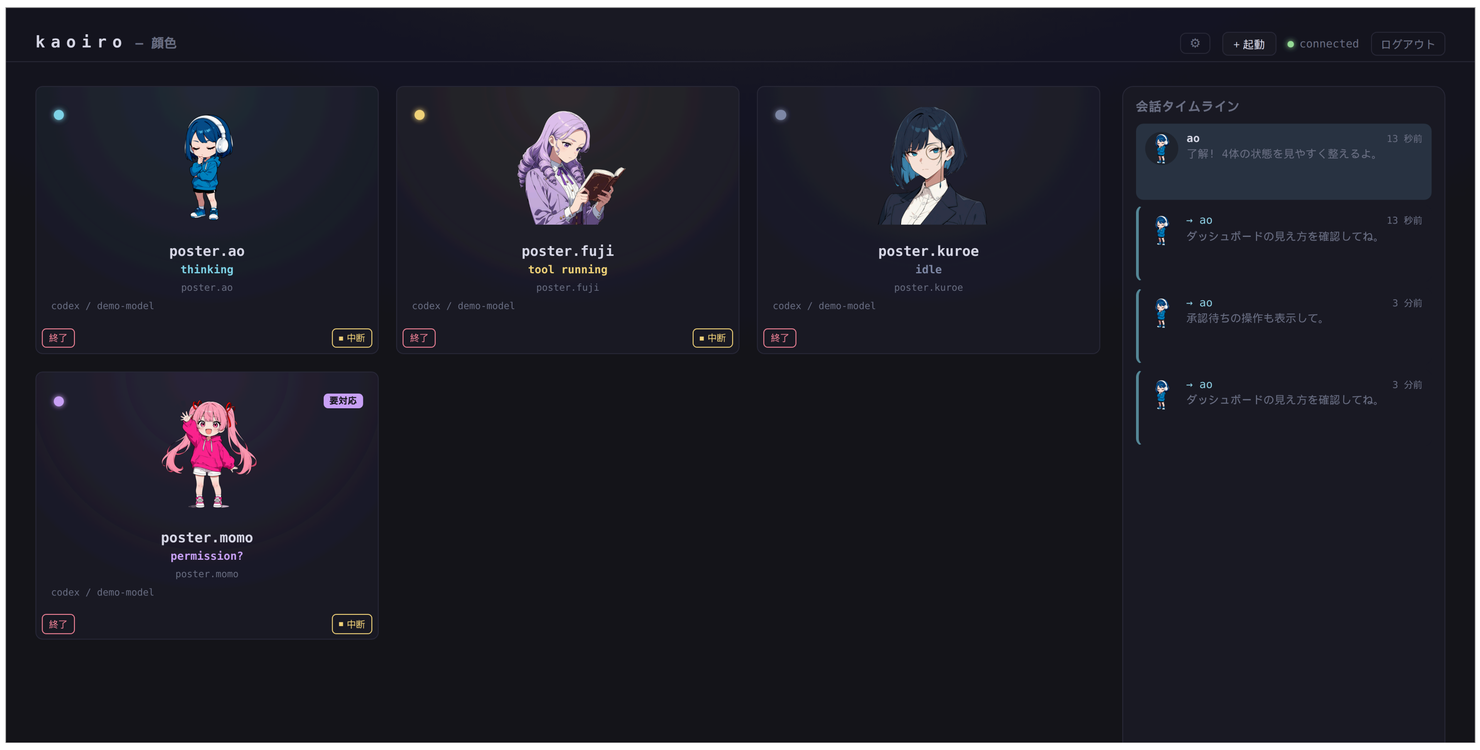
本ポスターが機能として示すのは (A) の状態可視化と、状態から表情への写像である。(B) への効果は評価していない。

一次信号 = 10 状態の状態機械

状態	意味
idle	待機
sending	指示を受理
thinking	推論中
tool_running	ツール実行中
waiting_permission	承認待ち
waiting_input	自由入力待ち
waiting_question	選択式質問待ち
done	完了
error	エラー
disconnected	接続断

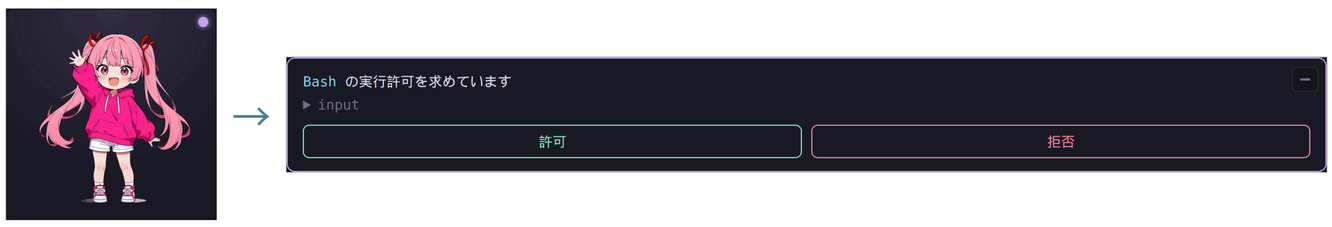
SDK が通知するイベント・コールバックから決定論的に導出する一次信号。端末画面の文字を読み取る方式ではない。

エージェント一覧画面(デモ用データ)



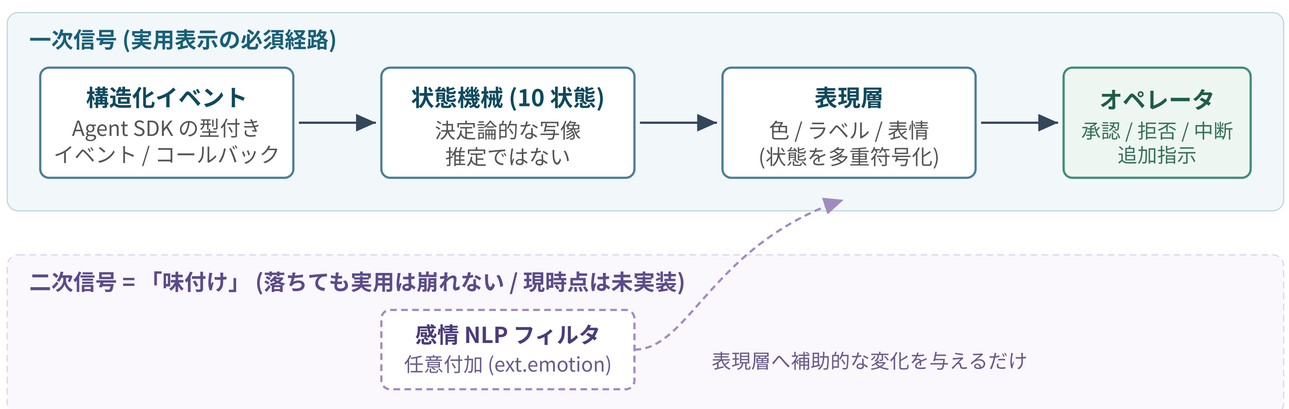
4 体のエージェントを色・状態ラベル・表情の 3 チャネルで一覧表示する画面の例。表示内容はデモ用データ。

承認待ち → 承認操作の接続



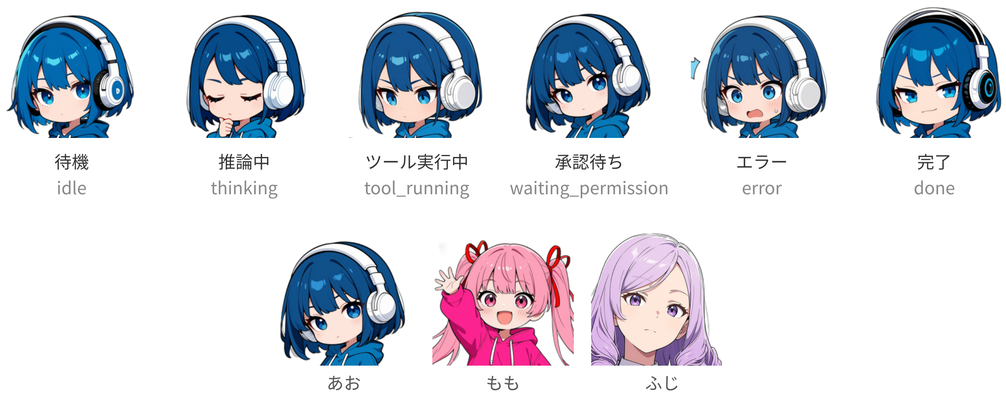
waiting_permission 状態の表示(左)から、実行予定の操作を許可・拒否する UI(右)へ同一画面上で接続する構成例(デモ用データ)。

設計の核:信号源の分離



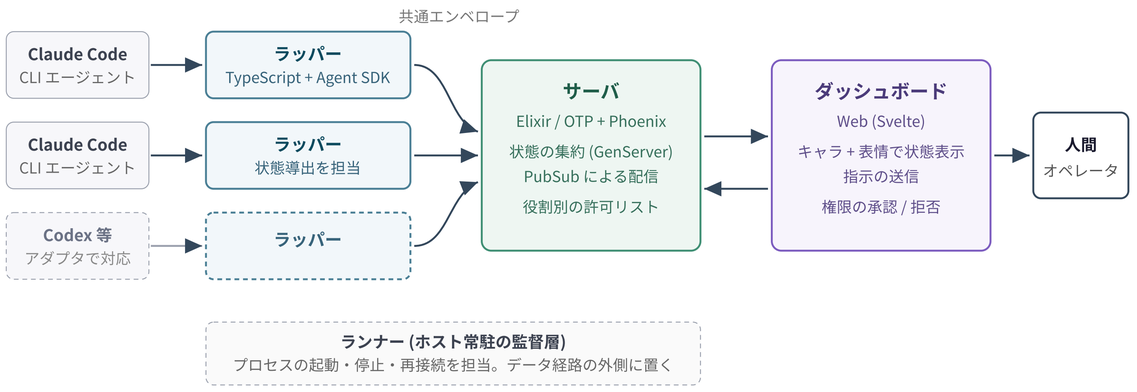
応答テキストの感情推定を一次信号にすると、「承認待ち」という統制点の検出が推定器に依存してしまう

状態 → 表情への mapping



実行状態(state)を表情(sprite)へ 1 対 1 で写像する構成。感情の推定ではない。同一状態 waiting_permission をキャラクター間で比較。

実装の構成



ラッパー 1 個 = エージェント 1 体 = プロセス 1 つ。サーバはエージェント非依存。ラッパー(TypeScript / Agent SDK)・サーバ(Elixir/Phoenix)・Web クライアントの 3 層構成(概略)。端末画面の文字を読み取る(スクレイピング)のではなく、SDK の型付きイベントから状態を導出する。

提案する軸



「エージェント同士の協調は、人間から見えるべきか、隠されるべきか」。隠蔽(opacity)と観測可能性(observability)の連続軸。kaoiro は観測可能性側の一端に位置する実装例。概念配置であり、各システムの全機能を分類するものではない。

このツールを用いて何を研究できるか



opacity と hidden action の分析上の接続。左の古典的な情報構造に対し、右の複数エージェント運用でも協調過程の観測可能性が設計変数になる。

行動・実験経済学 — 権限承認は人間側の逐次的意思決定。表示条件(生ログ / 状態ラベル / 表情 / 両方)を切り替えた比較で、状態理解の正確さ・異常発見までの時間・不適切な承認・拒否の率を測る研究計画。誘因を統制した報酬設計の下で、appropriate reliance を『システムの信頼性と行為のリスクに応じて承認行動を変えること』と操作的に定義し、その成立条件を検証する。

経営情報学 — opacity は、協調過程の観測可能性が低いという点で hidden action の分析枠組みと接続できる。可視化はオペレータの情報集合を変える設計として読める。委任境界(取引費用)や調整メカニズム(直接監督〜標準化)の分析枠組みと接続し、組織におけるマルチエージェント運用の設計課題を記述する。

HAI / CSCW・ガバナンス — HAI/CSCW における信頼校正研究の題材、状態機械を用いた運用教育、監査可能性・ガバナンス設計の検討。

連絡先:櫻井 雄大(桃山学院大学) sakurai@andrew.ac.jp